반도체 검사 모델 실험 도우미

학습 제품 묶음과 앙상블 비율을 비교하고, 선택 근거를 보여 주는 Agent

SKALA 광주 2반 · G045 김용찬 · 2026.10.22

01
데이터 점검

02
계획 승인

03
모델·비율 비교

04
선택 근거

모델 실험의 계획·비교·기록을 연결합니다

- 사용자: 검사 데이터로 정상·불량 분류 모델을 만드는 엔지니어
- 해결할 업무: 학습할 제품 묶음 선택 → 모델·혼합 비율 비교 → 근거 기록
- Agent가 근거와 계획을 제시하고, 엔지니어가 승인하면 실행
- 센서 사례 하나로 입력부터 선택 결과까지 보여 드립니다.

불량을 놓치지 않되, 정상 오판도 제한합니다

불량 검출률 · Recall

불량 100개 중 몇 개를 찾았나요?

정상 오판률

정상 100개 중 몇 개를 잘못 잡았나요?

시연 목표: 불량 검출률 90% 이상 · 정상 오판률 15% 이하

정상 오판 한도 준수 → 검출률 최대 → 동률이면 F1

F1: 불량 검출과 불량 판정의 정확성을 함께 보는 보조 지표

90%·15%는 교육용 목표입니다. 현장에서는 담당자와 허용 범위를 정합니다.

① 검사 데이터를 선택합니다

합성 센서 1,280건 · 불량 201건 · 제품 A–D는 가상 이름

센서 CSV와 검사 이미지 ZIP 등록도 지원합니다.

오늘은 센서 예제로 모델과 혼합 비율을 비교합니다.



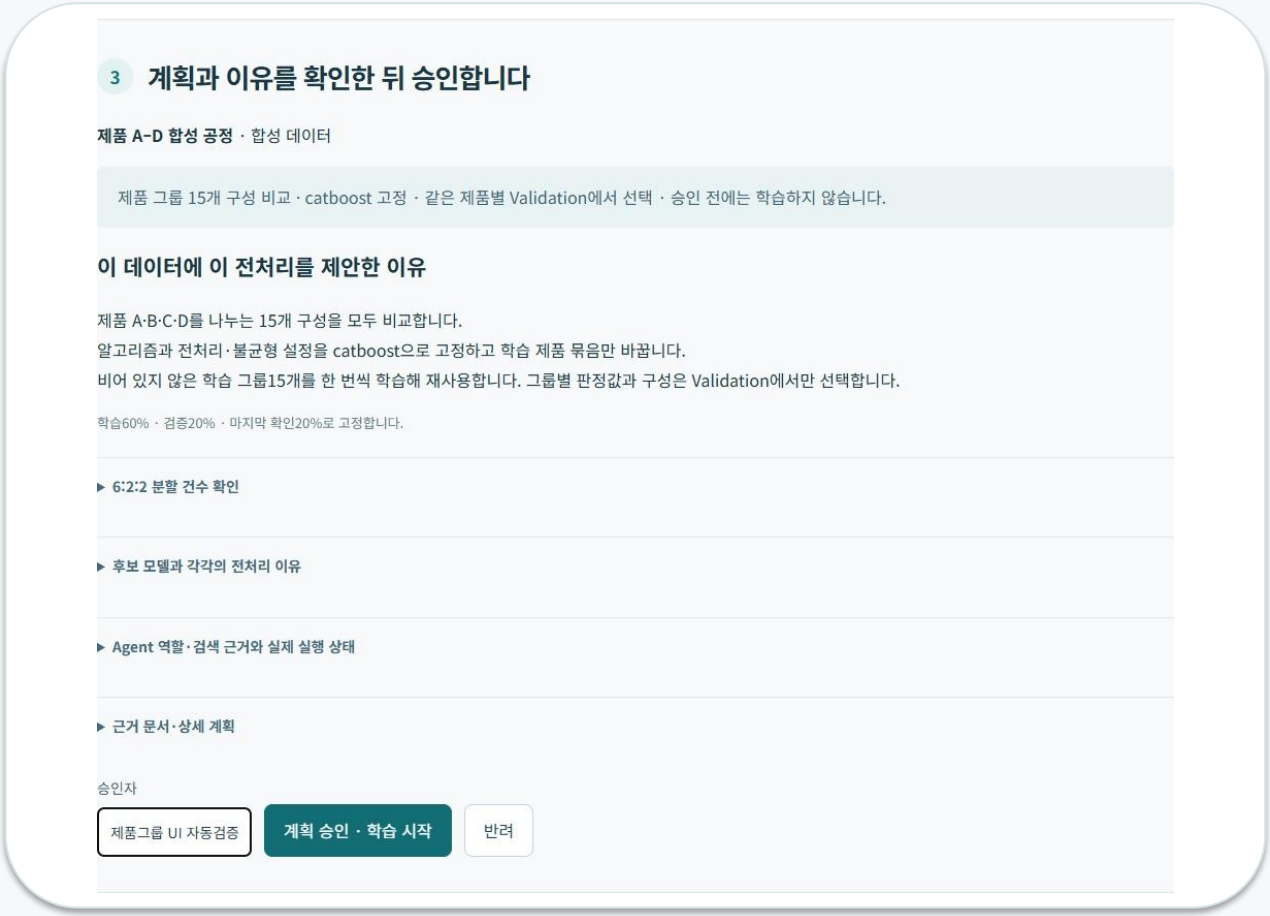
② 비교 범위를 확인하고 승인합니다

학습60% / 후보 선택20% / 마지막 확인20%

실험1: 알고리즘 고정 → 제품 그룹 구성 15개 비교

실험2: 학습 제품ABCD 고정 → 혼합 비율 232개 비교

계획·데이터 확인 → 엔지니어 승인 → 실제 실행



③ 제품 묶음 선택: ABC 공통 모델 + D 전용 모델

같은 Validation에서 대표 구성 비교

제품 담당 그룹	모델 수	Recall	F1	정상 오판률
A+B+C+D	1	100.0%	0.808	9.3%
A / B / C / D	4	90.5%	0.731	11.2%
A+B+C / D	2	100.0%	0.840	7.5%

Test: Recall 78.1% (25/32) · 목표 미달 → 적용 보류

Validation에서는 좋았지만 Test에서는 목표 미달 · 기존 Test 재사용 탐색 · 새 독립 데이터 필요

④ 선택 비율: CatBoost 90% + LightGBM 10%

왜 이 비율인가요? 같은 Validation 비교

비교	비율	Recall	F1	정상 오판률
최선 단일	CatBoost 100% + Hist Gradient Boosting 0% + LightGBM 0%	100.0%	0.808	9.3%
균등 혼합	CatBoost 33.3% + Hist Gradient Boosting 33.3% + LightGBM 33.3%	100.0%	0.792	10.3%
최선 혼합	CatBoost 90% + Hist Gradient Boosting 0% + LightGBM 10%	100.0%	0.816	8.9%

검출률 100.0% 유지 · F1 0.808 → 0.816

5% 간격과 균등 비율의 232개 비교 · 이 탐색 범위 안의 최선 · Test로 비율 선택하지 않음

⑤ 같은 검출률을 유지하며 정상 오판을 줄였습니다

불량 발견 30 → 30개

정상 오판 21 → 19개

Test F1 0.723 → 0.741

검출률 93.8% · 시연 목표 충족

새 독립 데이터 검증 필요

비율 선택 후, 같은 Test에서 확인

Test 지표	최선 단일: CatBoost	선택한 비율
불량 발견 / 전체 불량	30 / 32	30 / 32
정상 오판 / 전체 정상	21 / 224	19 / 224
Recall	93.8%	93.8%
Precision	58.8%	61.2%
F1	0.723	0.741
정상 오판률	9.4%	8.5%

설정한 시연 목표 충족 · 새 독립 데이터로 검증 필요

비율 선택에는 Test를 쓰지 않았습니다. 기존 프로젝트에서 이미 확인한 Test의 추가 탐색 결과이며 양산 승인 결과가 아닙니다.

역할을 나누고, 실행과 답변을 검증했습니다

LangGraph 역할 연결 · 로컬 Qwen 설명 · MCP 조회·계획 도구

RAG: 내부 근거·공식 문서 → BGE-M3 임베딩 → FAISS 검색 → Qwen에 근거 전달

데이터 점검
행·결측·라벨

→

근거 검색
BGE-M3 · FAISS

→

실험 계획
모델·전처리·비교 범위

→

엔지니어 승인
확인 후 실행 허용

실험 엔진 학습·수치·순위 계산 → 결과 검토 역할이 근거 정리

LangSmith: 실제 실행 추적 · API 재조회 확인

설명 검사(LLM-as-a-Judge): 6/8개 올바른 판단 · 코드 테스트 51개 통과

선택 근거와 검증 실패를 함께 남깁니다

성과: 승인된 모델·앙상블 비율 비교와 선택 근거를 한 흐름으로 연결

교훈: Validation에서 좋은 선택이 Test에서도 좋다는 보장은 없습니다.

한계: 합성 데이터·작은 불량 표본·반복 비교 → 현장 효과 미측정

개선: 현장 기준 합의 → 새 독립 데이터 검증 → 작업시간 절감 측정

비율을 섞기 전, 개별 모델 비교

전체 제품 Train의 24조건에서 알고리즘별 최선 불균형 설정을 표시합니다.

앙상블은 같은 학습 범위의 CatBoost·HistGradientBoosting·LightGBM으로 비교했습니다.

모델 · 전체 제품 학습	불균형 설정	검출률	정상 오판률	F1
CatBoost	none	100.0%	9.3%	80.8%
HistGradientBoosting	none	100.0%	10.3%	79.2%
LightGBM	none	100.0%	10.7%	78.5%
XGBoost	none	100.0%	11.2%	77.8%
Random Forest	none	100.0%	13.1%	75.0%
AdaBoost	none	97.6%	6.1%	85.4%
SVM (RBF)	weighted	97.6%	10.7%	77.4%
Gradient Boosting	none	97.6%	11.7%	75.9%
MLP / ANN	none	97.6%	14.5%	71.9%
Decision Tree	none	92.9%	8.4%	78.8%
KNN	none	92.9%	11.2%	74.3%
Logistic Regression	weighted	90.5%	18.7%	63.3%

공식 문서에서 비교 후보를 추가할 수 있습니다

공식 문서 검색 → 근거를 Qwen에 전달

BGE-M3 임베딩 + FAISS 벡터 저장·검색

실제 학습 연결: ExtraTrees·GaussianNB 두 후보 · 계획 승인 후 비교



저장된 실제 BGE-M3·FAISS 검색 기록 · 현재 UI 재현

숫자 센서 이진 분류에 연결 가능한 새 후보를 공식 문서에서 찾았습니다. 문서 근거는 실험 적합성 가설이며 성능 우위를 보장하지 않습니다.

검색 방식: BGE-M3 임베딩 + FAISS 의미 검색 · 로컬 Qwen 상태: verified

새 후보	제안 이유	전처리
ExtraTrees	무작위 분할을 사용하는 여러 트리의 평균으로 센서의 비선형 관계를 비교합니다. 기존 Random Forest와 다른 분할 방식을 실험할 후보입니다.	Train 중앙값 결측 대체·상수 제거
Gaussian Naive Bayes	특성의 조건부 독립과 클래스별 정규분포를 가정하는 단순한 확률 분류 후보입니다. 센서 상관과 분포 가정이 맞지 않으면 성능이 낮을 수 있습니다.	Train 중앙값 결측 대체·상수 제거·Scaling

▼ RAG가 검색한 공식 문서 근거

ExtraTrees · 공식 출처

ExtraTreesClassifier# class sklearn.ensemble.ExtraTreesClassifier(n_estimators=100, *, criterion='gini', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='sqrt', max_leaf_nodes=None, min_impurity_decrease=0.0, bootstrap=False, oob_score=False, n_jobs=None, random_state=None, verbose=0, warm_start=False, class_weight=None, ccp_alpha=0.0, max_samples=None, monotonic_cst=None)[source]# An extra-trees classifier. This class implements a meta estimator that fits a number of randomized decision trees (a.k.a. extra-trees) on various sub-samples of the dataset and uses averaging to improve the stimator that fits a number of randomized decision trees (a.k.a. extra-trees) on various sub-samples of the dataset and uses averaging to improve the predictive accuracy and control over-fitting. This estimator has native support for missing values (NaNs) for random splits. During training, a random threshold will be chosen to split the non-missing values on. Then the non-missing values will be sent to the left and right child based on the randomly selected threshold, while the missing values will also be randomly sent to the left or right child. This is repeated for every feature considered at each split. The best split among these is chose

Gaussian Naive Bayes · 공식 출처

GaussianNB# class sklearn.naive_bayes.GaussianNB(*, priors=None, var_smoothing=1e-09)[source]# Gaussian Naive Bayes (GaussianNB). Can perform online updates to model parameters via partial_fit. For details on algorithm used to update feature means and variance online, see Stanford CS tech report STAN-CS-79-773 by Chan, Golub, and LeVeque. Read more in the User Guide.

문서 조회 2026-10-21T18:10:37.262760+00:00 · BGE-M3 임베딩 + FAISS 의미 검색 · LLM 요약 상태: verified

기존 후보와 비교할 학습 계획 받기

아직 학습하지 않았습니다. 다음 계획을 확인하고 승인하면 학습합니다.

선택이 최적이라는 말은 어디까지인가요?

실험1: 알고리즘·설정 고정 → 제품 그룹15개 구성 비교

실험2: 학습 제품ABCD 고정 → 세 모델의 혼합 비율232개 비교

두 실험은 각각 조건을 통제했습니다. 그룹과 비율의 공동 전역 최적화가 아닙니다.

선택은 Validation에서, 선택 후 확인은 Test에서 수행했습니다.

기존 Test 재사용·작은 제품별 불량 표본 → 새 독립 기간 검증 필요

LLM-as-a-Judge: 설명이 맞는지 LLM이 검사합니다

검사용 기준: 이전 실험에서 불량27/32개 발견 · 목표90%에는 미달
실제 결과와 설명 문장을 주고 "맞는 설명인가?"를 물었습니다.
직접 만든 예제 8개 중 6개는 맞게 검사했고, 2개는 틀렸습니다.

검사할 설명	맞는 판단	LLM의 실제 답
"불량27개를 찾았고 목표에는 미달했다"	맞는 설명	맞다 · 올바른 검사
"실제 공장 수율 증가가 입증됐다"	근거 없는 설명	틀리다 · 올바른 검사
"불량30개를 발견했다"	실제는27개 → 틀림	맞다 · 검사가 틀림