반도체 검사 모델 실험 도우미

데이터에 맞는 모델을 비교하고, 승인받아 학습하는 Agent

G045 김용찬 · SK AI Leader Academy · 과제 2

데이터 종류에 따라 쓰는 모델이 다릅니다

데이터 종류	반도체 업무 활용 예시	교육자료의 모델 예시
검사 이미지	불량 이미지 분류 단면 길이 분석	ResNet · VGGNet GAN · Autoencoder
자연어·로그	장비 불량 유형 분류 공정 로그 분석	LSTM · GPT · BERT
시계열	수율 분석 산포 분석	LSTM · ARIMA Autoencoder

이번 구현: 검사 이미지와 숫자 센서의 정상·불량 분류

자연어 로그 분석·시계열 예측은 향후 확장 범위

반복할 모델 실험을 Agent에게 맡깁니다

사용 상황: 새 검사 데이터에 어떤 모델을 쓸지 비교합니다.

엔지니어는 계획을 검토하고, Agent는 승인받은 실험을 실행합니다.

순서	엔지니어의 행동	Agent가 보여 주는 내용
1. 입력	검사 데이터 선택	데이터 상태와 비교 계획
2. 승인	모델·전처리 계획 확인 후 승인	실제 학습과 Validation 비교
3. 결론	기본 모델과 후보 결과 확인	불량 발견·정상 오판·추가 실험 판단

데이터 선택 후 비교 계획을 요청합니다



선택: 제품 A–D 합성 센서 1,280건, 불량201건

엔지니어 행동: 비교 목표를 정하고 “비교 계획 제안받기” 클릭

계획의 이유를 확인하고 학습을 승인합니다



학습60% · 검증20% · 마지막 확인20%로 고정
생산 묶음(lot)이 학습·평가에 섞이지 않도록 분리합니다.

후보는 골랐지만, 추가 실험이 필요합니다

4 같은 Test 데이터에서 기본 모델과 후보를 비교합니다

비교 완료

제품 A–D 합성 공정 · 합성 데이터 실험

이번 실험의 선택 후보: CatBoost

기본 비교 모델: **Logistic Regression** · 기본 판정값 0.5
후보의 학습 제품: **A+B+C** · 학습 544개

판단: 추가 실험이 필요합니다
불량 검출률 84.4%: 데모 목표 90% 미달
Validation으로 후보를 골랐고, 아래는 마지막 Test 결과입니다.
현장 적용 모델 확정과 자동 배포는 수행하지 않습니다.

같은 Test **256개**에서 비교했습니다. 실제 불량 32개, 정상 224개입니다.

같은 Test에서 비교	기본: Logistic Regression	후보: CatBoost
불량 발견	20 / 32개	27 / 32개
놓친 불량	12개	5개
정상을 불량으로 오판	1 / 224개	14 / 224개
불량 검출률 (Recall)	62.5%	84.4%

기본: Logistic Regression / 선택 후보: CatBoost · A+B+C 학습

Test 불량27/32개 발견. 목표 미달로 추가 실험 필요

데이터를 바꾸면 모델과 결론도 달라집니다

데이터	기본 모델 / 선택 후보	불량 발견 기본 / 후보	정상 오판 기본 / 후보	Agent의 결론
합성 센서 제품 A–D	Logistic / CatBoost 후보 학습: A+B+C	20 / 27 (불량32개)	1 / 14 (정상224개)	Recall84.4% 추가 실험 필요
UCI SECOM 공개 센서	Logistic / XGBoost XGBoost는 참고 결과	0 / 5 (불량23개)	17 / 87 (정상357개)	목표 충족 후보 없음 데이터·계획 재검토
합성 이미지	축소 ResNet / Autoencoder	15 / 14 (불량15개)	32 / 0 (정상105개)	Recall93.3% 불량 표본 보강 필요

기본 / 후보 순으로 표시했습니다. 각 행의 Test는 서로 다릅니다.

UCI SECOM: 공개 반도체 센서·합격/불합격 기록, McCann & Johnston(2008)

Recall을 우선하되 정상 오판도 함께 봅니다

지표	쉽게 말하면	이번 프로젝트에서의 역할
Recall	실제 불량 중 몇 개를 찾았나?	불량을 놓치지 않는 목표를 우선 확인
정상 오판률	실제 정상 중 몇 개를 불량으로 잘못 봤나?	Recall만 높이는 후보를 걸러내는 목표
Precision · F1	불량 판정의 정확성과 Recall의 균형	후보의 장단점을 함께 보는 보조 지표

먼저 중요한 불량의 검출 목표와 정상 오판 허용 목표를 정합니다.

현재90%·15%는 교육용 시연 목표입니다. 회사별 기준은 별도 합의합니다.

공식 문서에서 새 후보를 찾아 실험합니다



공식 모델 목록 검색 · RAG 근거 확인 · 계획 승인 · 실제 학습

센서 ExtraTrees·GaussianNB 실험 후 CatBoost 유지. 새 후보 이력을 저장했습니다.

검사 모델을 비교하고 다음 실험을 판단합니다

사용: 데이터 선택, 계획 승인, 기본 모델과 후보 비교

추가: 새 모델 탐색 RAG, 재학습, 합친 학습·제품별 학습 비교

한계: 합성 데이터·작은 불량 표본·Test 재사용 탐색 비교

다음: 현장 데이터와 담당자 기준으로 독립 기간 검증

점검 후, 승인받아 같은 알고리즘을 재학습합니다

같은 알고리즘을 다시 학습한 결과

CatBoost · 새 배치의 동일 Test에서 비교했습니다.

같은 Test에서 측정	기존 모델 그대로	같은 알고리즘 재학습
실제 불량을 발견	43 / 167개	153 / 167개
놓친 불량	124개	14개
정상을 불량으로 오판	96 / 601개	79 / 601개
불량 검출률 (Recall)	25.7%	91.6%
정상 오판률	16.0%	13.1%

새 합성 배치의 같은 Test: 불량 발견 43/167개에서 153/167개
정상 오판 96개에서 79개. Recall·정상 오판 시연 목표 충족. 회사 적용은 별도 검증

제품별로 합친 학습과 개별 학습을 비교합니다

제품을 합쳐 학습할까요, 제품마다 따로 학습할까요?

아래 비율은 같은 제품의 Validation에서 비교합니다. 동률이면 관리할 모델 수가 적은 합친 학습을 선택합니다.

제품	여러 제품을 합쳐 학습 검출률 / 정상 오판률	이 제품만 학습 검출률 / 정상 오판률	고른 방식 · Test 확인
A	98.6% / 14.8%	94.2% / 14.2%	여러 제품을 합쳐 학습 여러 제품을 합쳐 학습한 후보
B	89.7% / 13.2%	89.7% / 14.9%	여러 제품을 합쳐 학습 추가 데이터로 재확인 필요
C	90.9% / 14.3%	93.2% / 14.3%	이 제품만 학습 추가 데이터로 재확인 필요
D	98.2% / 8.3%	98.2% / 13.9%	여러 제품을 합쳐 학습 추가 데이터로 재확인 필요

C 제품: 같은 Validation에서 “C만 학습” 후보 선택

C의 별도 Test Recall79.1%. 추가 데이터로 재확인 필요

Validation으로 고르고, Test로 마지막 확인합니다

선택 후보의 Test 결과	Recall	Precision	F1	정상 오판률
합성 센서	84.4%	65.9%	74.0%	6.3%
UCI 공개 센서 SECOM	21.7%	5.4%	8.7%	24.4%
합성 이미지	93.3%	100.0%	96.6%	0.0%

Train은 학습, Validation은 후보·판정값 비교, Test는 마지막 확인

합성 센서 Train60%(768개) / Validation20%(256개) / Test20%(256개)

같은 생산 묶음(lot)·날짜 경계를 보존합니다. 후보의 제품 범위에 따라 Train 실사용 수는 다릅니다.

F1은 보조 지표입니다. Test 점수를 보며 분할·후보를 조정하지 않습니다.

공개 반도체 공정 데이터: UCI SECOM

McCann, M. & Johnston, A. (2008). SECOM [Dataset].

UCI Machine Learning Repository · DOI: 10.24432/C54305 · CC BY4.0

archive.ics.uci.edu/dataset/179/secom

자료	입력과 정답	한계·최종 Test 결과
UCI SECOM 공개 원본	1,567건·센서590열 합격/불합격 기록·불합격104건	제조사명·제품ID 제공 없음 불량5/23개 발견·정상87/357개 오판
합성 센서 / 합성 이미지	가상 제품 A–D / 연습용 패턴	실제 생산 데이터·SEM 이미지 아님 이미지 불량14/15개 발견

앙상블 비율도 Validation에서 비교하는 확장

확장 단계	Agent가 설명할 내용
1. 같은 입력·고정 분할	동일 입력·라벨의 모델1·모델2를 Train으로 학습
2. 승인받아 비율 비교	0:100,25:75,50:50,75:25,100:0 등 예시 실험안 측정한 최적값 아님
3. Validation에서 선택	Recall 우선·정상 오판 함께 확인. 목표 미달이면 추가 실험
4. 고정된 Test로 확인	선택 비율을 고정해 단일 모델과 비교. 두 모델 운영 부담 확인

현재: RF·부스팅 사용. 서로 다른 모델의 혼합 비율 탐색은 미구현

6:2:2 분할을 비교 전에 고정하고 “실험한 비율 중 가장 좋은 후보”로 설명

기술 요소가 반영된 위치

기술 요소	구현 위치	확인 상태
Multi-Agent	planner.py · advisors.py	데이터 점검·계획·결과 검토 역할
RAG	discovery.py · Knowledge	공식 외부 문서 검색·후보 제안·승인 후 학습
MCP	mcp_server.py	4도구·지식 resource 실제 연결
의존성 주입	Dependencies · Workbench	Store·Knowledge·Advisor 주입
모듈화	app/ 데이터·학습·관리 모듈	API·MCP가 공통 엔진 재사용
단위/API 테스트	tests/	30개 테스트 통과

상세 대응표: docs/ASSIGNMENT_CHECKLIST.md