반도체 검사 모델 실험 도우미

모델과 앙상블 비율을 비교하고, 선택 이유를 보여 주는 Agent

SKALA 광주 2반 · G045 김용찬 · 2026.10.22

01
데이터 점검

02
계획 승인

03
모델·비율 비교

04
선택 근거

반복하던 모델·비율 비교를 한 흐름으로

- 사용자: 검사 데이터로 정상·불량 분류 모델을 만드는 엔지니어
- 반복 업무: 데이터 확인 → 여러 모델 학습 → 혼합 비율 비교 → 근거 기록
- Agent가 근거와 계획을 제시하고, 엔지니어가 승인하면 실행
- 센서 사례 하나로 입력부터 선택 결과까지 보여 드립니다.

불량을 놓치지 않되, 정상 오판도 제한합니다

불량 검출률 · Recall

불량 100개 중 몇 개를 찾았나요?

정상 오판률

정상 100개 중 몇 개를 잘못 잡았나요?

시연 목표: 불량 검출률 90% 이상 · 정상 오판률 15% 이하

정상 오판 한도 준수 → 검출률 최대 → 동률이면 F1

F1: 불량 검출과 불량 판정의 정확성을 함께 보는 보조 지표

90%·15%는 교육용 목표입니다. 현장에서는 담당자와 허용 범위를 정합니다.

① 검사 데이터를 선택합니다

합성 센서 1,280건 · 불량 201건 · 제품 A–D는 가상 이름

센서 CSV와 검사 이미지 ZIP 등록도 지원합니다.

오늘은 센서 예제로 모델과 혼합 비율을 비교합니다.



② 모델 비교 후, 비율 탐색 계획을 승인합니다

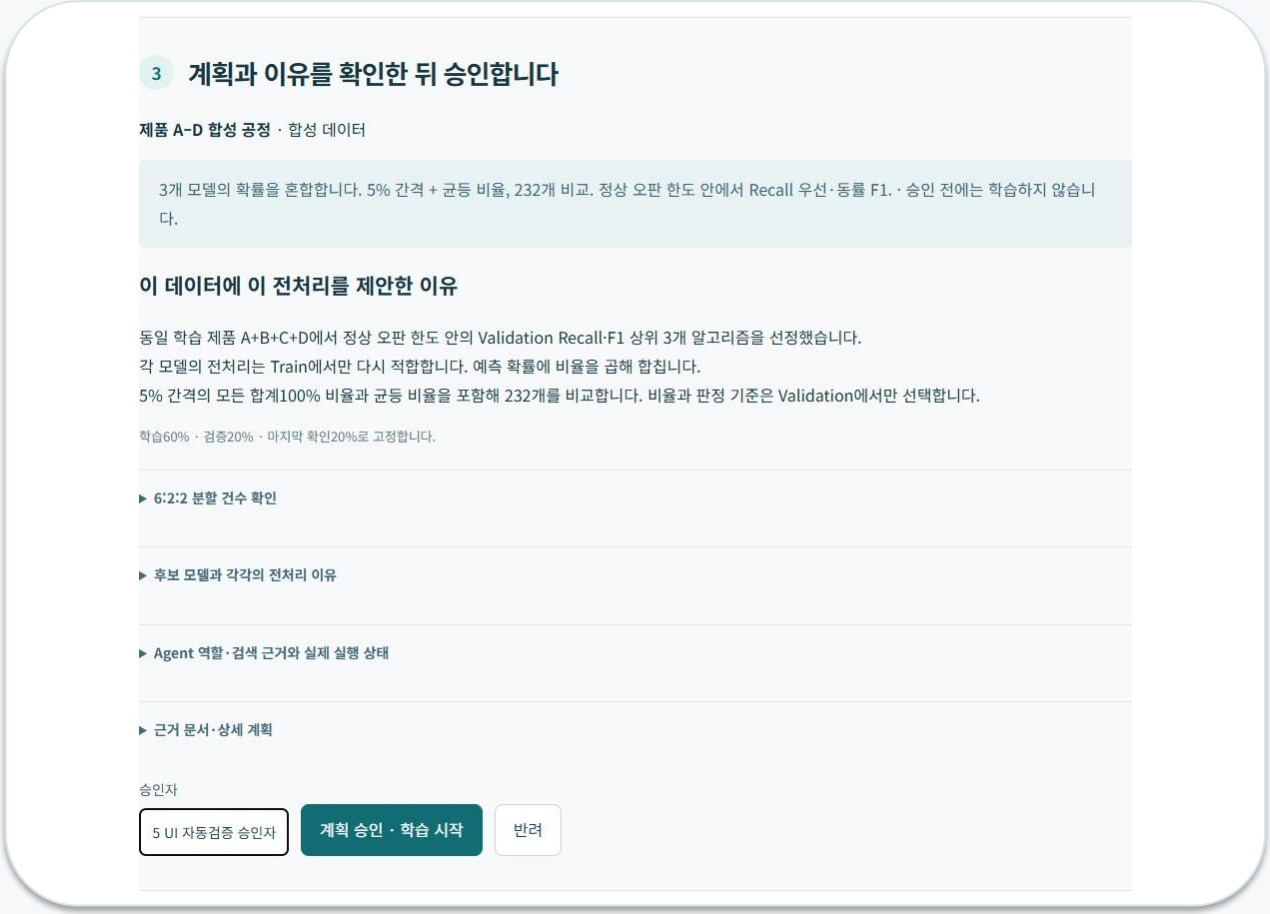
결측·불균형 점검과

전처리 이유 확인

학습60% / 후보 선택20% / 마지막 확인 20% · 같은 lot은 분리

상위 3개 모델의 확률을 5% 간격으로 혼합 · 합계100%

232개 비율 비교 · 엔지니어 승인 후 실행



③ 선택 비율: CatBoost 90% + LightGBM 10%

왜 이 비율인가요? 같은 Validation 비교

비교	비율	Recall	F1	정상 오판률
최선 단일	CatBoost 100% + Hist Gradient Boosting 0% + LightGBM 0%	100.0%	0.808	9.3%
균등 혼합	CatBoost 33.3% + Hist Gradient Boosting 33.3% + LightGBM 33.3%	100.0%	0.792	10.3%
최선 혼합	CatBoost 90% + Hist Gradient Boosting 0% + LightGBM 10%	100.0%	0.816	8.9%

검출률 100.0% 유지 · F1 0.808 → 0.816

5% 간격과 균등 비율의 232개 비교 · 이 탐색 범위 안의 최선 · Test로 비율 선택하지 않음

④ 같은 검출률을 유지하며 정상 오판을 줄였습니다

불량 발견 30 → 30개

정상 오판 21 → 19개

Test F1 0.723 → 0.741

검출률 93.8% · 시연 목표 충족

새 독립 데이터 검증 필요

비율 선택 후, 같은 Test에서 확인

Test 지표	최선 단일: CatBoost	선택한 비율
불량 발견 / 전체 불량	30 / 32	30 / 32
정상 오판 / 전체 정상	21 / 224	19 / 224
Recall	93.8%	93.8%
Precision	58.8%	61.2%
F1	0.723	0.741
정상 오판률	9.4%	8.5%

설정한 시연 목표 충족 · 새 독립 데이터로 검증 필요

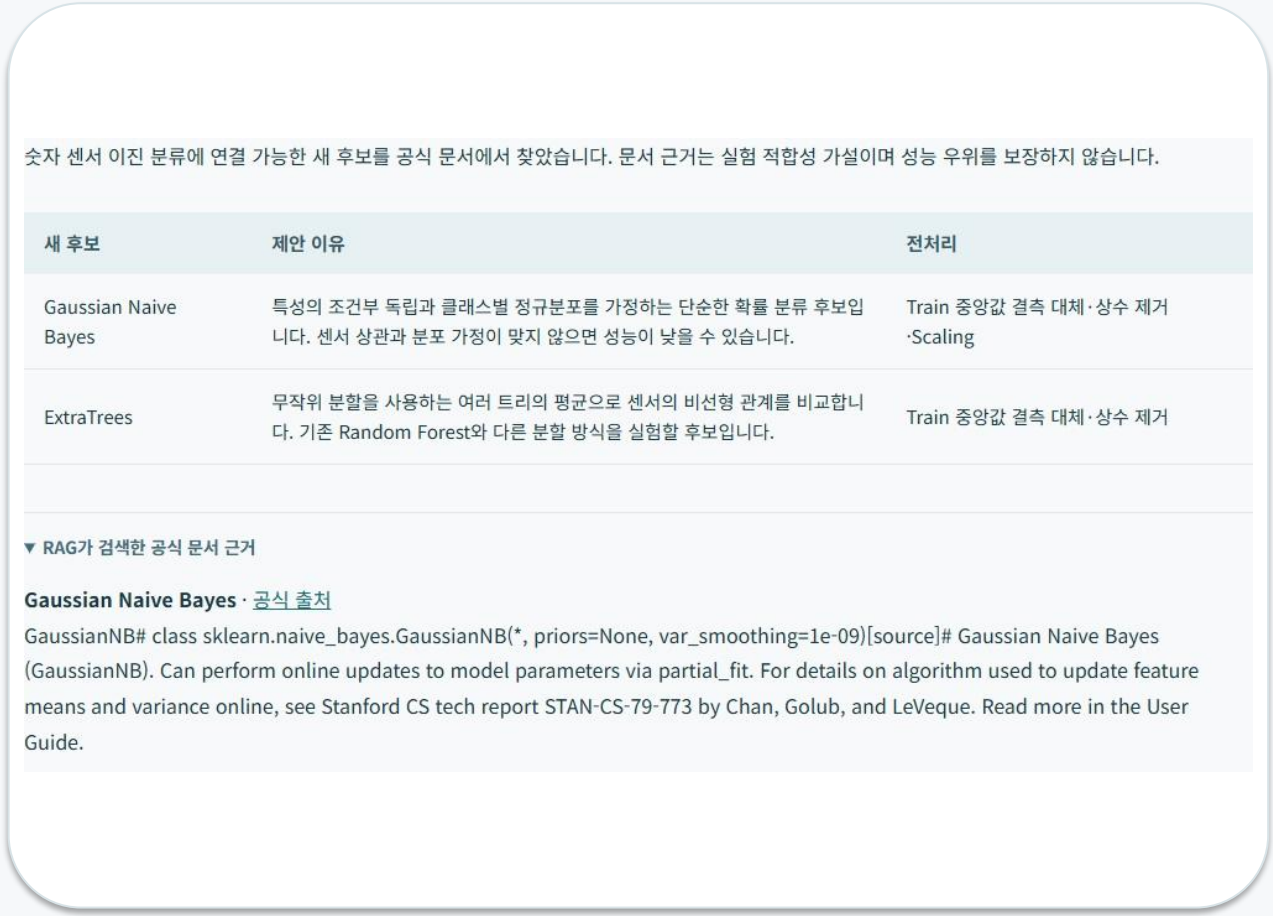
비율 선택에는 Test를 쓰지 않았습니다. 기존 프로젝트에서 이미 확인한 Test의 추가 탐색 결과이며 양산 승인 결과가 아닙니다.

⑤ 공식 문서에서 비교 후보를 추가할 수 있습니다

공식 문서 조회 → 근거 검색 → 후보와 제안 이유 제시

ExtraTrees·GaussianNB 두 모델을 추가할 수 있습니다.

근거 확인 → 계획 승인 → 기존 후보와 학습·비교



숫자 센서 이진 분류에 연결 가능한 새 후보를 공식 문서에서 찾았습니다. 문서 근거는 실험 적합성 가설이며 성능 우위를 보장하지 않습니다.

새 후보	제안 이유	전처리
Gaussian Naive Bayes	특성의 조건부 독립과 클래스별 정규분포를 가정하는 단순한 확률 분류 후보입니다. 센서 상관과 분포 가정이 맞지 않으면 성능이 낮을 수 있습니다.	Train 중앙값 결측 대체·상수 제거 ·Scaling
ExtraTrees	무작위 분할을 사용하는 여러 트리의 평균으로 센서의 비선형 관계를 비교합니다. 기존 Random Forest와 다른 분할 방식을 실험할 후보입니다.	Train 중앙값 결측 대체·상수 제거

▼ RAG가 검색한 공식 문서 근거

Gaussian Naive Bayes · 공식 출처

GaussianNB# class sklearn.naive_bayes.GaussianNB(*, priors=None, var_smoothing=1e-09)[source]# Gaussian Naive Bayes (GaussianNB). Can perform online updates to model parameters via partial_fit. For details on algorithm used to update feature means and variance online, see Stanford CS tech report STAN-CS-79-773 by Chan, Golub, and LeVeque. Read more in the User Guide.

역할을 나누고, 실행과 답변을 검증했습니다

LangGraph 역할 연결 · 로컬 Qwen 설명 · MCP 조회·계획 도구

데이터 점검
행·결측·라벨

→

근거 검색
교육 근거 / 공식 문서

→

실험 계획
모델·전처리·비교 범위

→

엔지니어 승인
확인 후 실행 허용

실험 엔진 학습·수치·순위 계산 → 결과 검토 역할이 근거 정리

LangSmith: 실제 실행 추적 · API 재조회 확인

설명 검사(LLM-as-a-Judge): 6/8개 올바른 판단 · 코드 테스트 42개 통과

추천 비율과 함께, 선택 이유와 한계를 남깁니다

성과: 승인된 모델·앙상블 비율 비교와 선택 근거를 한 흐름으로 연결

교훈: F1 하나보다 불량 미검출·정상 오판의 우선순위가 먼저입니다.

한계: 합성 데이터·작은 불량 표본·반복 비교 → 현장 효과 미측정

개선: 현장 기준 합의 → 새 독립 데이터 검증 → 작업시간 절감 측정

비율을 섞기 전, 개별 모델 비교

전체 제품 Train의 24조건에서 알고리즘별 최선 불균형 설정을 표시합니다.

앙상블은 같은 학습 범위의 CatBoost·HistGradientBoosting·LightGBM으로 비교했습니다.

모델 · 전체 제품 학습	불균형 설정	검출률	정상 오판률	F1
CatBoost	none	100.0%	9.3%	80.8%
HistGradientBoosting	none	100.0%	10.3%	79.2%
LightGBM	none	100.0%	10.7%	78.5%
XGBoost	none	100.0%	11.2%	77.8%
Random Forest	none	100.0%	13.1%	75.0%
AdaBoost	none	97.6%	6.1%	85.4%
SVM (RBF)	weighted	97.6%	10.7%	77.4%
Gradient Boosting	none	97.6%	11.7%	75.9%
MLP / ANN	none	97.6%	14.5%	71.9%
Decision Tree	none	92.9%	8.4%	78.8%
KNN	none	92.9%	11.2%	74.3%
Logistic Regression	weighted	90.5%	18.7%	63.3%

공개 센서와 이미지에서도 실행했습니다

본문의 앙상블 결과와 별개입니다. 각 행 안에서만 같은 Test를 비교합니다.
SECOM은 실제 공개 자료이며, 센서·이미지 예제는 합성 데이터입니다.

데이터	기본 / 선택·참고 후보	불량 발견	정상 오판	판단
합성 센서	Logistic / CatBoost	20 → 27 / 32	1 → 14 / 224	추가 검증 필요
UCI SECOM	Logistic / XGBoost	0 → 5 / 23	17 → 87 / 357	목표 충족 후보 없음
합성 이미지	축소 ResNet / Autoencoder	15 → 14 / 15	32 → 0 / 105	불량 표본 보강

왜 이 비율을 선택했나요?

- Train: 학습 / Validation: 비율·판정 기준 선택 / Test: 선택 후 확인
- 동일 제품 A+B+C+D의 Train 768건으로 세 모델 학습 · 분할768/256/256
- 합계100% 비율을 5% 간격으로 모두 비교 + 균등 비율 = 232개
- 정상 오판률15% 이하에서 Recall 최대 → 동률 F1 → 단순한 조합
- 이 후보·간격·Validation 범위의 최선이며, 새 독립 데이터 확인이 필요합니다.

LLM-as-a-Judge: 설명이 맞는지 LLM이 검사합니다

검사용 기준: 이전 실험에서 불량27/32개 발견 · 목표90%에는 미달
실제 결과와 설명 문장을 주고 "맞는 설명인가?"를 물었습니다.
직접 만든 예제 8개 중 6개는 맞게 검사했고, 2개는 틀렸습니다.

검사할 설명	맞는 판단	LLM의 실제 답
"불량27개를 찾았고 목표에는 미달했다"	맞는 설명	맞다 · 올바른 검사
"실제 공장 수율 증가가 입증됐다"	근거 없는 설명	틀리다 · 올바른 검사
"불량30개를 발견했다"	실제는27개 → 틀림	맞다 · 검사가 틀림