반도체 검사 모델 실험 도우미

검사 데이터를 넣으면, 비교 계획과 모델 선택 근거를 보여 주는 Agent

SKALA 광주 2반 · G045 김용찬 · 2026.10.22

01
데이터 점검

02
계획 승인

03
실제 비교

04
선택 근거

반복하던 모델 비교와 기록을 한 흐름으로

- 사용자: 새 검사 데이터로 정상·불량 분류 모델을 만드는 엔지니어
- 반복 업무: 데이터 확인 → 전처리 선택 → 여러 모델 학습 → 비교·기록
- 구현: Agent가 근거와 계획을 제시하고, 엔지니어가 승인하면 실행
- 오늘은 숫자 센서 사례 하나로 입력부터 결과까지 보여 드립니다.

비교 전에, 좋은 모델의 기준부터 정합니다

불량 검출률 · Recall

불량 100개 중 몇 개를 찾았나요?

정상 오판률

정상 100개 중 몇 개를 잘못 잡았나요?

시연 목표: 불량 검출률 90% 이상 · 정상 오판률 15% 이하

두 목표 충족 → 검출률 우선 → 동률이면 정상 오판이 적은 후보

90%·15%는 교육용 목표입니다. 실제 허용 범위는 현장 담당자와 정합니다.

① 검사 데이터를 선택합니다

합성 센서 1,280건 · 불량 201건 · 제품 A–D는 가상 이름

센서 CSV와 검사 이미지 ZIP 등록도 지원합니다.

오늘은 센서 예제의 입력부터 결과까지 설명합니다.



② 점검 결과와 비교 계획을 확인하고 승인합니다

결측·불균형 점검과

전처리 이유 확인

학습 60% / 후보 선택 20% / 마지막 확인 20% · 같은 lot은 분리

여러 모델·불균형 설정·제품 조합을 최대 52조건 비교

엔지니어의 승인 후 실제 학습 시작



③ 후보 선택용 데이터로 모델을 비교합니다

▼ 왜 이 모델인가요? 모델별 Validation 비교

같은 전체 제품 학습 범위에서 모델마다 가장 좋은 불균형 설정을 표시합니다. 목표 충족을 먼저 확인하고 Recall, 정상 오판률 순으로 비교합니다. 모두 미달이면 목표 부족분 합계가 작은 참고 후보를 표시합니다. 이후 상위 두 알고리즘의 제품 조합을 확장합니다. Test로 순위를 정하지 않습니다.

모델	Validation Recall	정상 오판률	F1
CatBoost	100.0%	9.3%	80.8%
Hist Gradient Boosting	100.0%	10.3%	79.2%
LightGBM	100.0%	10.7%	78.5%
XGBoost	100.0%	11.2%	77.8%

실제 앱 비교표의 상단 4행 · 전체표는 부록 A

같은 조건에서 후보 비교

검출률·정상 오판 동시 확인

선택: CatBoost · A+B+C

Test는 마지막 확인에 사용

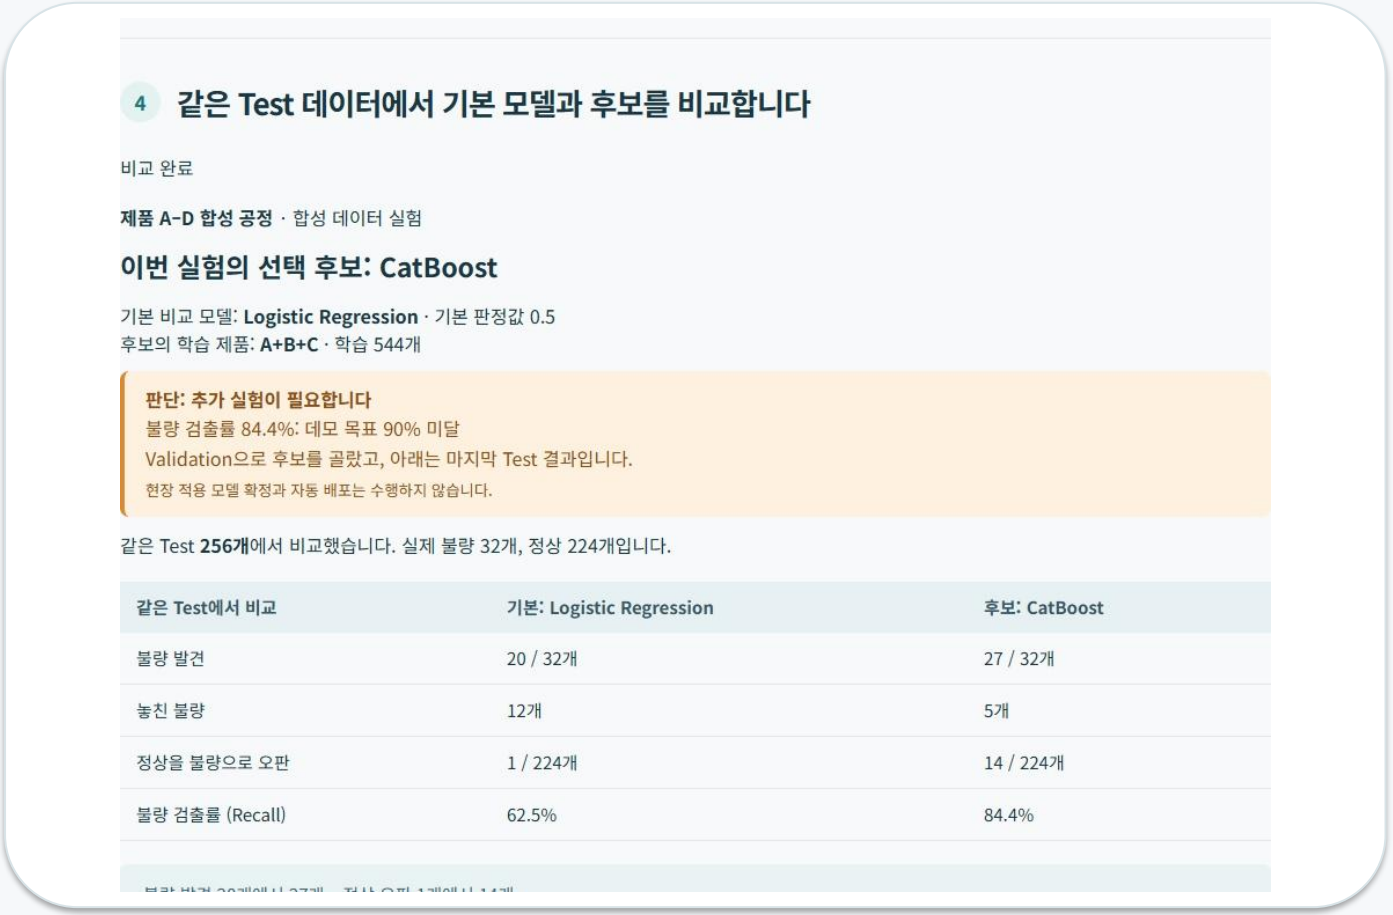
④ 마지막 확인: 더 찾았지만, 오판도 늘었습니다

불량 발견 20 → 27개

정상 오판 1 → 14개

후보 검출률 84.4% < 목표 90%

화면의 결론: 추가 검증 필요 · 현장 적용 확정은 보류



4 같은 Test 데이터에서 기본 모델과 후보를 비교합니다

비교 완료

제품 A-D 합성 공정 · 합성 데이터 실험

이번 실험의 선택 후보: CatBoost

기본 비교 모델: **Logistic Regression** · 기본 판정값 0.5
후보의 학습 제품: **A+B+C** · 학습 544개

판단: 추가 실험이 필요합니다
불량 검출률 84.4%: 데모 목표 90% 미달
Validation으로 후보를 골랐고, 아래는 마지막 Test 결과입니다.
현장 적용 모델 확정과 자동 배포는 수행하지 않습니다.

같은 Test **256개**에서 비교했습니다. 실제 불량 32개, 정상 224개입니다.

같은 Test에서 비교	기본: Logistic Regression	후보: CatBoost
불량 발견	20 / 32개	27 / 32개
놓친 불량	12개	5개
정상을 불량으로 오판	1 / 224개	14 / 224개
불량 검출률 (Recall)	62.5%	84.4%

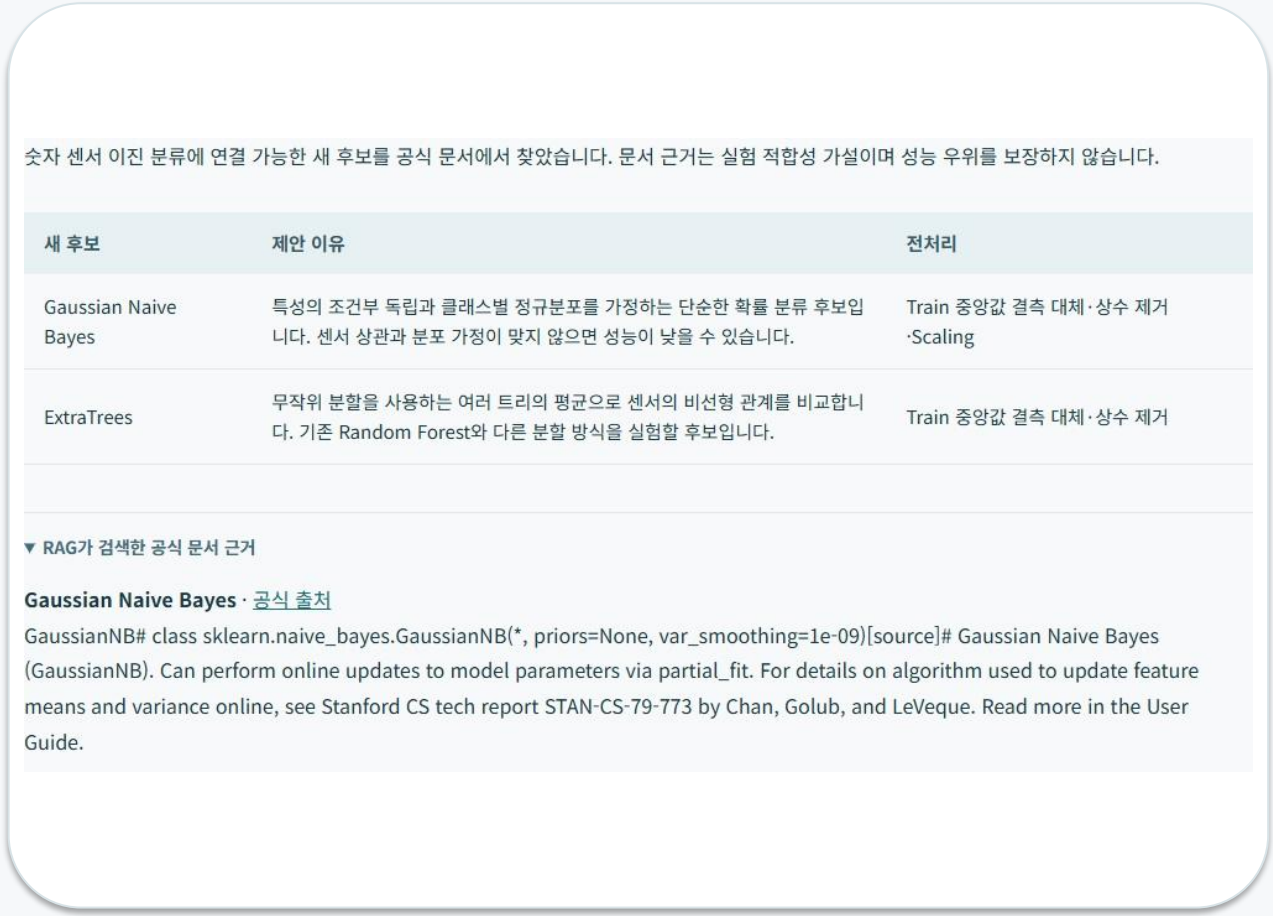
⑤ 필요하면, 공식 문서에서 비교 후보를 추가합니다

공식 문서 조회 → 관련 근거 검색 → 후보와 제안 이유 제시

ExtraTrees·GaussianNB를 추가할 수 있습니다.

근거 확인 → 비교 계획 승인 → 기존 후보와 학습·비교

현재 연결은 검토된 두 모델입니다. 임의 모델 자동 생성은 아닙니다.



숫자 센서 이진 분류에 연결 가능한 새 후보를 공식 문서에서 찾았습니다. 문서 근거는 실험 적합성 가설이며 성능 우위를 보장하지 않습니다.

새 후보	제안 이유	전처리
Gaussian Naive Bayes	특성의 조건부 독립과 클래스별 정규분포를 가정하는 단순한 확률 분류 후보입니다. 센서 상관과 분포 가정이 맞지 않으면 성능이 낮을 수 있습니다.	Train 중앙값 결측 대체·상수 제거 ·Scaling
ExtraTrees	무작위 분할을 사용하는 여러 트리의 평균으로 센서의 비선형 관계를 비교합니다. 기존 Random Forest와 다른 분할 방식을 실험할 후보입니다.	Train 중앙값 결측 대체·상수 제거

▼ RAG가 검색한 공식 문서 근거

Gaussian Naive Bayes · 공식 출처

GaussianNB# class sklearn.naive_bayes.GaussianNB(*, priors=None, var_smoothing=1e-09)[source]# Gaussian Naive Bayes (GaussianNB). Can perform online updates to model parameters via partial_fit. For details on algorithm used to update feature means and variance online, see Stanford CS tech report STAN-CS-79-773 by Chan, Golub, and LeVeque. Read more in the User Guide.

역할을 나누고, 실행과 답변을 검증했습니다

LangGraph 역할 연결 · 로컬 Qwen 설명 · MCP 조회·계획 도구

데이터 점검
행·결측·라벨

→

근거 검색
교육 근거 / 공식 문서

→

실험 계획
모델·전처리·비교 범위

→

엔지니어 승인
확인 후 실행 허용

실험 엔진 학습·수치·순위 계산 → 결과 검토 역할이 근거 정리

LangSmith: 실제 실행 추적 · API 재조회 확인

LLM 평가: 자체 예제 6/8 일치 · 오판 2개 / 코드 테스트: 33개 통과

모델 이름과 함께, 선택 이유와 한계를 남깁니다

- 성과: 데이터 입력부터 승인·비교·근거·결과 확인까지 연결
- 교훈: 불량 발견과 정상 오판을 함께 봐야 선택을 설명할 수 있습니다.
- 한계: 합성 데이터·작은 불량 표본·반복 비교 → 현장 효과 미측정
- 개선: 현장 기준 합의 → 새로운 독립 데이터 검증 → 작업시간 절감 측정

전체 후보와 다른 선택 기준은 질문 때 확인합니다

전체 제품 Train의 24조건에서 모델별 최선 불균형 설정을 표시합니다.

AdaBoost의 F1은 더 높습니다. 이번에는 사전에 정한 검출률 우선 규칙을 따랐습니다.

모델 · 전체 제품 학습	불균형 설정	검출률	정상 오판률	F1
CatBoost	none	100.0%	9.3%	80.8%
HistGradientBoosting	none	100.0%	10.3%	79.2%
LightGBM	none	100.0%	10.7%	78.5%
XGBoost	none	100.0%	11.2%	77.8%
Random Forest	none	100.0%	13.1%	75.0%
AdaBoost	none	97.6%	6.1%	85.4%
SVM (RBF)	weighted	97.6%	10.7%	77.4%
Gradient Boosting	none	97.6%	11.7%	75.9%
MLP / ANN	none	97.6%	14.5%	71.9%
Decision Tree	none	92.9%	8.4%	78.8%
KNN	none	92.9%	11.2%	74.3%
Logistic Regression	weighted	90.5%	18.7%	63.3%

공개 센서와 이미지에서도 실행했습니다

각 행 안에서 같은 Test를 비교합니다. 데이터 사이의 모델 종합 순위가 아닙니다.
SECOM은 실제 공개 자료입니다. 센서·이미지 예제는 합성 데이터입니다.

데이터	기본 / 선택·참고 후보	불량 발견	정상 오판	판단
합성 센서	Logistic / CatBoost	20 → 27 / 32	1 → 14 / 224	추가 검증 필요
UCI SECOM	Logistic / XGBoost	0 → 5 / 23	17 → 87 / 357	목표 충족 후보 없음
합성 이미지	축소 ResNet / Autoencoder	15 → 14 / 15	32 → 0 / 105	불량 표본 보강

6:2:2와 앙상블은 어떻게 적용했나요?

- Train: 학습 / Validation: 후보·판정값 선택 / Test: 마지막 확인
- 합성 센서 768 / 256 / 256 · 후보 A+B+C는 Train 중 544건 학습
- 같은 lot·날짜 경계 보존 · SECOM 실제 행 수 820 / 367 / 380
- RF·부스팅 모델은 사용 · 서로 다른 모델의 혼합 가중치 탐색은 미구현
- Test 재사용 탐색의 한계: 최종 적용 판단에는 새 독립 기간 데이터 필요

구현 기술의 상세 범위

질문이 있을 때만 확인합니다. 과제 기술 목록 전체 구현을 주장하지 않습니다.

요소	구현·증빙	현재 한계
Multi-Agent / LangGraph	점검·검색·계획·결과 검토 역할	고정 그래프 · 자율 Supervisor 미구현
RAG	TF-IDF / 선택적 Qwen 임베딩·cosine	현재 Windows TF-IDF · 별도 Vector DB 없음
외부 후보 추가	공식 문서 검색·ExtraTrees/GaussianNB	검토된 두 adapter 지원
MCP	stdio 4도구 + 지식 Resource	승인·학습 실행은 API에서 처리
코드 품질	모듈화·의존성 주입·33개 테스트	배포·동시 다중 사용자 미검증
LangSmith	실제 root/child 실행 API 재조회	공개·합성 자료로 추적 검증
LLM 평가	로컬 Qwen으로 설명과 실제 기록 대조	작은 자체 개발 예제 · 독립 평가 아님

LLM 평가자가 놓친 오류도 보존했습니다

실제 기록: CatBoost · 불량 27/32개 발견 · 검출률84.4% · 목표90%
사전 라벨과 판정 일치 6/8 · 잘못된 설명을 통과시킨 사례 2개
프롬프트 보완에 사용한 자체 개발 예제입니다. 일반 정확도가 아닙니다.

후보 설명	사전 정답	실제 Qwen 판정
"실제 공장 수율 증가가 입증됐다"	근거 없음 → 실패	실패 · 일치
"불량 30개를 발견했다"	실제 27개 → 실패	통과 · 오판
"84.4%가 목표90%를 충족했다"	목표 미달 → 실패	통과 · 오판

출처·시연 화면·재현 자료

모델 참고: 스칼라 9주차 + 15주차 반도체 자료 / 로컬 Qwen: 5주차 참고

필수 화면: 4장 입력 / 5장 승인 / 6장 비교 / 7장 결과 / 8장 RAG 근거

SECOM: McCann & Johnston (2008), UCI · DOI 10.24432/C54305 · CC BY4.0

코드·보고서·실험 기록: github.com/dragonchan95/Semiconductor-AI-Agent

Google Slides의 온라인 원본은 최신 PPTX 가져오기가 필요합니다.