반도체 검사 모델 실험·관리 Agent

모델 비교부터 성능 점검·재학습까지 다음 실험을 돕습니다.

SKALA 광주 2반 · G045 김용찬 · 2026.10.22

01
데이터 점검

02
계획 승인

03
모델·비율 비교

04
성능 점검·재학습

입력 데이터에 맞는 모델을 비교합니다

입력에 맞는 후보·전처리 제안 후, 승인·실험·성능 점검으로 연결합니다.

입력 데이터	모델 예	현재 구현
센서 표	Tree·Forest·Boosting, SVM·KNN·MLP 등12종	실제 비교·제품 묶음·재학습
검사 이미지	축소 ResNet·VGGNet, Autoencoder	실제 학습 비교
이미지 추가 후보	EfficientNet, GAN	미실행·미구현
연속 시계열	LSTM·ARIMA·Autoencoder	전용 데이터·예측 목표 미준비
장비 로그 텍스트	LSTM·BERT·GPT	로그·정답 데이터 미준비

오늘 본문은 센서 분류입니다. 입력 종류별로 따로 비교합니다.

불량을 놓치지 않으면서, 정상도 지킵니다

불량을 정상으로 놓침

불량이 다음 공정·고객으로

넘어갈 위험이 있습니다.

Recall: 불량100개 중 찾아낸 비율

정상을 불량으로 오판

불필요한 확인·보류가 늘고

정상 제품을 제외할 위험이 있습니다.

정상 오판률: 정상100개 중 잘못 잡은 비율

정상 오판을 제한한 뒤, 불량을 가장 많이 찾는 모델 선택

동률이면 F1: 불량을 잘 찾고, 불량 판정도 정확한지 함께 확인

시연 목표: Recall90% 이상 · 정상 오판률15% 이하 (교육용 수치)

전부 불량으로 판정하면 Recall100%지만, 정상 오판도100%입니다.

① 검사 데이터를 선택합니다

오늘 본문: 합성 센서1,280건 · 제품 A–D는 가상 이름

표시한 성능은 실제 학습으로 측정했습니다.

UCI SECOM은 실제 공개 자료로 별도 실험했습니다.



② 비교 범위를 확인하고 승인합니다

빈값 처리·필요한 Scaling은 학습용 데이터로만 준비

학습60% · 후보 선택20% · 마지막 시험20%

제품 묶음15개와 예측 혼합 비율232개를 각각 비교

계획과 데이터를 확인하고 승인한 뒤 실제 학습



③ 개별 모델 비교와 선택 근거

같은 센서 후보 선택용 데이터에서 알고리즘별 최선 불균형 설정을 표시합니다.

CatBoost: Recall100%·F1 0.808 / AdaBoost: Recall97.6%·F1 0.854

모델 · 전체 제품 학습	불균형 설정	검출률	정상 오판률	F1
CatBoost	none	100.0%	9.3%	0.808
HistGradientBoosting	none	100.0%	10.3%	0.792
LightGBM	none	100.0%	10.7%	0.785
XGBoost	none	100.0%	11.2%	0.778
Random Forest	none	100.0%	13.1%	0.750
AdaBoost	none	97.6%	6.1%	0.854
SVM (RBF)	weighted	97.6%	10.7%	0.774
Gradient Boosting	none	97.6%	11.7%	0.759
MLP / ANN	none	97.6%	14.5%	0.719
Decision Tree	none	92.9%	8.4%	0.788
KNN	none	92.9%	11.2%	0.743
Logistic Regression	weighted	90.5%	18.7%	0.633

④ 제품 묶음 비교: ABC는 함께, D는 따로 학습

같은 Validation에서 대표 구성 비교

제품 담당 그룹	모델 수	Recall	F1	정상 오판률
A+B+C+D	1	100.0%	0.808	9.3%
A / B / C / D	4	90.5%	0.731	11.2%
A+B+C / D	2	100.0%	0.840	7.5%

Test: Recall 78.1% (25/32) · 목표 미달 → 적용 보류

Validation에서는 좋았지만 Test에서는 목표 미달 · 기존 Test 재사용 탐색 · 새 독립 데이터 필요

⑤ 선택 비율: CatBoost 90% + LightGBM 10%

왜 이 비율인가요? 같은 Validation 비교

비교	비율	Recall	F1	정상 오판률
최선 단일	CatBoost 100% + Hist Gradient Boosting 0% + LightGBM 0%	100.0%	0.808	9.3%
균등 혼합	CatBoost 33.3% + Hist Gradient Boosting 33.3% + LightGBM 33.3%	100.0%	0.792	10.3%
최선 혼합	CatBoost 90% + Hist Gradient Boosting 0% + LightGBM 10%	100.0%	0.816	8.9%

검출률 100.0% 유지 · F1 0.808 → 0.816

5% 간격과 균등 비율의 232개 비교 · 이 탐색 범위 안의 최선 · Test로 비율 선택하지 않음

⑥ 같은 검출률을 유지하며 정상 오판을 줄였습니다

불량 발견 30 → 30개

정상 오판 21 → 19개

Test F1 0.723 → 0.741

검출률 93.8% · 시연 목표 충족

새 독립 데이터 검증 필요

비율 선택 후, 같은 Test에서 확인

Test 지표	최선 단일: CatBoost	선택한 비율
불량 발견 / 전체 불량	30 / 32	30 / 32
정상 오판 / 전체 정상	21 / 224	19 / 224
Recall	93.8%	93.8%
Precision	58.8%	61.2%
F1	0.723	0.741
정상 오판률	9.4%	8.5%

설정한 시연 목표 충족 · 새 독립 데이터로 검증 필요

비율 선택에는 Test를 쓰지 않았습니다. 기존 프로젝트에서 이미 확인한 Test의 추가 탐색 결과이며 양산 승인 결과가 아닙니다.

⑦ 새 정답 데이터로 기존 모델을 점검합니다



재학습 필요
기존 CatBoost의 모델과 판정값을 바꾸지 않고 점검했습니다.

같은 제품	이전 Test 검출률	새 데이터 검출률	새 데이터 정상 오판률	제안
A	4/4개	37/112개	20.5%	재학습 비교 제안
B	3/4개	45/130개	18.1%	재학습 비교 제안
C	10/14개	35/121개	20.7%	재학습 비교 제안
D	10/10개	33/109개	22.3%	재학습 비교 제안

점검 기준: 불량 표본 20개 이상에서 검출 목표 미달·정상 오판 목표 초과·이전보다 Recall 10%p 넘게 하락 시 재학습 비교를 제안합니다. 표본이 부족하면 판단을 보류합니다.

같은 제품·같은 모델·같은 판정 경계값으로 새 배치의 학습 구간을 점검. 10%p 하락·불량 20개는 교육용 점검 규칙이며 회사 기준·통계적 확증이 아님. 과거 제품별 표본이 작으면 하락 폭도 탐색적 해석. 새

새 배치의 정답으로 기존 모델 그대로 점검

검출 목표 미달
재학습 비교 제안

표본이 부족하면
판단 보류

판단 근거를 확인한 뒤 학습 계획을 승인합니다. 입력 변화만으로 즉시 교체하지 않습니다.

⑧ 승인 후 재학습하고, 같은 Test에서 비교합니다

재학습 전후, 새 배치의 같은 Test에서 확인했습니다

CatBoost 알고리즘은 유지하고 새 Train으로 다시 학습했습니다. 불량 167개·정상 601개를 같은 정답으로 비교합니다.

> **시연 목표 충족 · 재학습 후보 저장**
> 불량 발견 43개 → 153개 · 놓친 불량 124개 → 14개 · 정상 오판 96개 → 79개

같은 Test에서 측정	기존 모델 그대로	같은 알고리즘 재학습
실제 불량을 발견	43 / 167개	153 / 167개
놓친 불량	124개	14개
정상을 불량으로 오판	96 / 601개	79 / 601개
불량 검출률 (Recall)	25.7%	91.6%
정상 오판률	16.0%	13.1%
Precision · 잡은 것 중 실제 불량	30.9%	65.9%

불량 발견
43 → 153 / 167개

Recall
25.7% → 91.6%

정상 오판
96 → 79개

같은 CatBoost·새 배치의 같은 Test에서 비교했습니다. 후보를 저장하고 운영 모델은 유지합니다.

이미지 모델도 별도로 학습해 비교했습니다

전처리2조건 중 모델별 최선. 단순 합성 패턴에서 세 모델이 같은 점수입니다.

이미지 모델	현재 상태	Recall	F1	정상 오판률
ResNet 계열 축소	실행 완료 · contrast	100.0%	1.000	0.0%
VGGNet 계열 축소	실행 완료 · contrast	100.0%	1.000	0.0%
Autoencoder	실행 완료 · contrast	100.0%	1.000	0.0%
EfficientNet	추가 후보 · 미구현	미실행	미실행	미실행

선택 Autoencoder의 Test는14/15개 발견. 불량 표본 부족으로 적용 판단은 보류했습니다.

공식 문서에서 비교 후보를 추가할 수 있습니다

공식 문서 검색 → 근거를 Qwen에 전달

BGE-M3 임베딩 + FAISS 벡터 저장·검색

실제 학습 연결: ExtraTrees·GaussianNB 두 후보 · 계획 승인 후 비교



역할을 나누고, 실행과 답변을 검증했습니다

LangGraph 역할 연결 · 로컬 Qwen 설명 · MCP 조회·계획 도구

RAG: 내부 근거·공식 문서 → BGE-M3 임베딩 → FAISS 검색 → Qwen에 근거 전달

데이터 점검
행·결측·라벨

→

근거 검색
BGE-M3 · FAISS

→

실험 계획
모델·전처리·비교 범위

→

엔지니어 승인
확인 후 실행 허용

실험·재학습 엔진 학습·지표·후보 버전 기록 → 결과 검토 역할이 근거 정리

LangSmith: 실제 실행 추적 · API 재조회 확인

설명 검사(LLM-as-a-Judge): 6/8개 올바른 판단 · 코드 테스트 52개 통과

LLM-as-a-Judge: 설명이 맞는지 LLM이 검사합니다

검사용 기준: 이전 실험에서 불량27/32개 발견 · 목표90%에는 미달

실제 결과와 설명 문장을 주고 “맞는 설명인가?”를 물었습니다.

직접 만든 예제 8개 중 6개는 맞게 검사했고, 2개는 틀렸습니다.

검사할 설명	맞는 판단	LLM의 실제 답
“불량27개를 찾았고 목표에는 미달했다”	맞는 설명	맞다 · 올바른 검사
“실제 공장 수율 증가가 입증됐다”	근거 없는 설명	틀리다 · 올바른 검사
“불량30개를 발견했다”	실제는27개 → 틀림	맞다 · 검사가 틀림

공개 데이터에서도 확인하고, 실패를 기록했습니다

- 합성 센서 앙상블: 불량30/32개 발견 · 정상19/224개 오판
- 실제 공개 SECOM: 불량5/23개 발견 · 정상87/357개 오판
- 공개 자료에서는 목표 미달. 합성 결과를 현장 성능으로 일반화할 수 없습니다.
- 개선: 현장 기준·독립 기간·충분한 불량 표본으로 다시 검증

과제 기술 요소와 실제 구현 위치

기술 요소	구현과 확인
Multi-Agent · LangGraph	점검·검색·계획 역할 연결 / 로컬 Qwen 설명
MCP	조회·계획 4개 도구와 지식 Resource
RAG	BGE-M3 임베딩 / FAISS 검색 / Qwen에 근거 전달
모듈화 · DI · 단위/API 테스트	학습·점검·저장 분리 / 의존성 주입 / 52개 통과
LangSmith	APAC 실제 계획 생성·하위 실행 API 재조회
LLM-as-a-Judge	개발 예제 8개 중 6개 판정 일치 / 오판 보존
모델 성능 관리	새 정답 배치 점검 / 승인 재학습 / 전후 비교·후보 저장