반도체 불량 판정 모델 선택·재학습 Agent

어떤 모델을 고르고, 언제 다시 학습할지 엔지니어에게 제안합니다.

G045 김용찬 · SK AI Leader Academy · 과제 2

엔지니어가 결정해야 할 세 가지

1 처음 쓸 모델: 데이터에 맞는 전처리와 모델은?

2 기존 제품: 새 데이터에서도 불량을 잘 잡는가?

3 여러 제품: 합쳐 학습할까, 제품마다 따로 학습할까?

SK하이닉스 공개 사례: 검사 AI의 성능 감시·성능 저하 후 복구·새 결함 학습

Recall이 우선, Precision·F1도 함께 확인

설명용 예시	불량으로 판정	정상으로 판정
실제 불량 10개	TP 9개 · 잘 잡음	FN 1개 · 놓침
실제 정상 90개	FP 3개 · 정상 오판	TN 87개 · 정상 통과

Recall 90%: 실제 불량 10개 중 9개를 발견

Precision 75%: 잡힌 12개 중 진짜 불량 9개

F1 81.8%: Precision과 Recall을 함께 반영

데이터 종류에 맞춰 전처리와 모델을 제안

입력	전처리와 이유	실제 비교 후보
숫자 공정 센서	결측 대체·상수 제거 거리·신경망 모델은 Scaling	교육 기반 센서 모델 12종
검사 이미지	흑백 32×32·0~1 Scaling 대비 보정도 비교	축소 ResNet·VGGNet Autoencoder

센서 12종: Logistic·Tree·RF·GB·XGBoost·LightGBM·CatBoost·KNN·SVM·MLP·AdaBoost·HistGB

A·B·C·D는 합성 데이터의 가상 제품명입니다.

계획을 승인받고 학습·검증·마지막 확인

데이터 구간	하는 일	이번 합성 센서 예시
학습 Train	모델·전처리 학습	896개
비교·검증 Validation	판정 경계값과 후보 선택	192개
마지막 확인 Test	고른 후보를 처음 보는 데이터로 확인	192개

Agent 제안 → 엔지니어 승인 → 실제 학습 → 결과 설명

최대 52조건 비교: 모델 12종 비교 후 상위 2종의 제품 조합 확장

불량은 더 찾았지만, 목표에는 아직 못 미침

동일 Test 192개	기본 Logistic	고른 후보
실제 불량 25개 중 발견	17개 (68.0%)	19개 (76.0%)
놓친 불량	8개	6개
정상 167개 중 불량으로 오판	1개 (0.6%)	8개 (4.8%)

후보: CatBoost · 학습 제품 A+B+C

Validation에서는 불량 34/34개 발견 → Test에서는 19/25개 발견

데모 목표 Recall 90%에 Test 76%가 못 미쳐 후보 재검토

기존 모델 점검 후, 승인받아 같은 알고리즘 재학습

새 합성 Test · 불량 127 / 정상 449	기존 모델 그대로	같은 알고리즘 재학습
불량 발견	24개 (18.9%)	117개 (92.1%)
놓친 불량	103개	10개
정상 오판	70개 (15.6%)	68개 (15.1%)

새 학습 구간에서 기존 모델·판정값을 고정해 제품별 점검 → 재학습 제안·승인

새 Test 576개에서 같은 알고리즘 비교: Recall 18.9% → 92.1%

정상 오판 15.1%는 데모 목표 15% 초과: 추가 확인 필요

여러 제품을 합칠까, C만 따로 학습할까?

C에서 비교한 학습 방식	불량 검출률	정상 오판률
A+B+C+D를 합쳐 학습	92.3%	17.0%
C 제품만 따로 학습	96.2%	13.8%

같은 C 제품의 Validation 데이터로 비교합니다.

C만 학습한 후보가 데모 목표를 만족해 선택됐습니다.

그러나 C의 Test 검출률은 86.1% → 추가 데이터로 재확인

실제 공개 반도체 센서에서도 실패를 확인

SECOM: UCI가 공개한 반도체 제조 공정 센서·합격/불합격 데이터

1,567건 · 센서 590열 · 불량 104건 · 실제 제품 A–D 정보 없음

검사 이미지는 별도의 합성 패턴이며 실제 SEM 이미지가 아닙니다.

독립 Test 결과	불량 발견	정상 오판	해석
실제 공개 센서 SECOM	6/15개	73/249개	데모 목표 미달
합성 이미지	6/14개	0/76개	검출률·표본 부족

계획의 이유와 판정 건수를 한 화면에서

1 데이터 선택 → 완료된 결과 확인

2 새 실험 계획의 전처리·모델 근거 확인 → 승인

3 새 데이터로 점검 → 재학습 계획 승인



4 같은 Test 데이터에서 기본 모델과 후보를 비교합니다

비교 완료

제품 A–D 합성 공정 · 합성 데이터 실측

데모 목표 미충족 또는 표본 부족 · 후보 재검토
불량 검출률 76.0%: 데모 목표 90% 미달
비교로 고른 후보: CatBoost · 학습 제품 A+B+C
후보 선정과 회사 적용 승인은 다릅니다. 자동 배포하지 않습니다.

아래 두 모델은 **동일한 Test 192개**에서 확인했습니다. 실제 불량 25개, 정상 167개입니다.

같은 Test에서 측정	기본 모델	비교로 고른 후보
실제 불량을 발견	17 / 25개	19 / 25개
놓친 불량	8개	6개
정상을 불량으로 오판	1 / 167개	8 / 167개
불량 검출률 (Recall)	68.0%	76.0%

설명·계획은 Agent, 실행은 승인 뒤에

데이터 점검 Agent → 근거 검색 → 실험 계획 Agent → 승인 → 학습 → 결과 검토 Agent

로컬 LLM: 허용된 판단 코드와 출처를 검사하고 실패하면 규칙 설명 사용

실험 엔진: 학습·지표 계산·파일 저장 · 운영 모델 자동 교체 없음

평가항목	실제 구현·확인
Multi-Agent · RAG	LangGraph 역할 분리 · 요약 근거 14개 검색
MCP · 의존성 주입 · 모듈화	MCP 4도구 실제 연결 · 공통 Workbench 재사용
단위/API 테스트	26개 테스트 통과

모델 선택과 재학습을 돕는 주제로 완성

핵심: 불량을 놓치지 않도록 Recall 우선, Precision·F1·정상 오판 함께 확인

회사 기준: 공개 자료에서 공통 합격 수치를 확인하지 못함 → 제품·공정 담당자가 정의

현재 한계: 작은 불량 표본·합성 데이터·단일 분할·반복 Validation 비교

다음 단계: 독립 기간 검증·현장 데이터·인증/권한·중앙 모델 관리

상세 지표와 재현 조건

Test 상세 · 선택 후보	Recall	Precision	F1	정상 오판률
합성 센서	76.0%	70.4%	73.1%	4.8%
공개 반도체 센서 SECOM	40.0%	7.6%	12.8%	29.3%
합성 이미지	42.9%	100.0%	60.0%	0.0%

순위: 데모 목표를 만족한 후보 중 Recall 우선, 동률이면 정상 오판이 적은 후보

F1은 보조 지표이며 순위 선정에 사용하지 않았습니다.

단일 seed 45 · 같은 lot 분리 · SECOM은 날짜 순서 분리

제품별 작은 표본·Validation 반복 사용으로 결과가 낙관적일 수 있습니다.

기술 요소가 반영된 위치

기술 요소	구현 위치	확인 상태
Multi-Agent	planner.py · advisors.py	점검·계획·결과 검토 역할
RAG	Knowledge · knowledge.json	근거 검색·출처 연결
MCP	mcp_server.py	4도구·지식 resource 실제 연결
의존성 주입	Dependencies · Workbench	Store·Knowledge·Advisor 주입
모듈화	app/ 데이터·학습·관리 모듈	API·MCP가 공통 엔진 재사용
단위/API 테스트	tests/	26개 테스트 통과

코드·실행 증빙의 자세한 연결: docs/ASSIGNMENT_CHECKLIST.md