반도체 검사 모델 실험·관리 Agent

모델 비교부터 성능 점검·재학습까지 다음 실험을 돕습니다.

SKALA 광주 2반 · G045 김용찬 · 2026.10.22

01
데이터 점검

02
계획 승인

03
모델·비율 비교

04
성능 점검·재학습

모델을 고를 때와 성능이 떨어졌을 때를 돕습니다

- 사용자: 검사 모델을 만들고 점검하는 엔지니어
- 처음: 데이터 점검·전처리 이유·모델·제품 묶음·혼합 비율 비교
- 이후: 새 정답 데이터로 성능 점검·재학습 필요성 판단·전후 비교
- Agent가 근거와 계획을 제시하고, 엔지니어 승인 후 학습합니다.

불량을 놓치지 않으면서, 정상도 지킵니다

불량을 정상으로 놓침

불량이 다음 공정·고객으로

넘어갈 위험이 있습니다.

Recall: 불량100개 중 찾아낸 비율

정상을 불량으로 오판

불필요한 확인·보류가 늘고

정상 제품을 제외할 위험이 있습니다.

정상 오판률: 정상100개 중 잘못 잡은 비율

정상 오판을 제한한 뒤, 불량을 가장 많이 찾는 모델 선택

동률이면 F1: 불량을 잘 찾고, 불량 판정도 정확한지 함께 확인

시연 목표: Recall90% 이상 · 정상 오판률15% 이하 (교육용 수치)

전부 불량으로 판정하면 Recall100%지만, 정상 오판도100%입니다.

① 검사 데이터를 선택합니다

합성 센서 1,280건 · 불량 201건 · 제품 A–D는 가상 이름

센서 CSV와 검사 이미지 ZIP 등록도 지원합니다.

오늘은 센서 예제로 모델과 혼합 비율을 비교합니다.



② 비교 범위를 확인하고 승인합니다

빈값 처리·필요한 Scaling은 학습용 데이터로만 준비

학습60% · 후보 선택20% · 마지막 시험20%

제품 묶음15개와 예측 혼합 비율232개를 각각 비교

계획과 데이터를 확인하고 승인한 뒤 실제 학습



③ 제품 묶음 비교: ABC는 함께, D는 따로 학습

같은 Validation에서 대표 구성 비교

제품 담당 그룹	모델 수	Recall	F1	정상 오판률
A+B+C+D	1	100.0%	0.808	9.3%
A / B / C / D	4	90.5%	0.731	11.2%
A+B+C / D	2	100.0%	0.840	7.5%

Test: Recall 78.1% (25/32) · 목표 미달 → 적용 보류

Validation에서는 좋았지만 Test에서는 목표 미달 · 기존 Test 재사용 탐색 · 새 독립 데이터 필요

④ 선택 비율: CatBoost 90% + LightGBM 10%

왜 이 비율인가요? 같은 Validation 비교

비교	비율	Recall	F1	정상 오판률
최선 단일	CatBoost 100% + Hist Gradient Boosting 0% + LightGBM 0%	100.0%	0.808	9.3%
균등 혼합	CatBoost 33.3% + Hist Gradient Boosting 33.3% + LightGBM 33.3%	100.0%	0.792	10.3%
최선 혼합	CatBoost 90% + Hist Gradient Boosting 0% + LightGBM 10%	100.0%	0.816	8.9%

검출률 100.0% 유지 · F1 0.808 → 0.816

5% 간격과 균등 비율의 232개 비교 · 이 탐색 범위 안의 최선 · Test로 비율 선택하지 않음

⑤ 같은 검출률을 유지하며 정상 오판을 줄였습니다

불량 발견 30 → 30개

정상 오판 21 → 19개

Test F1 0.723 → 0.741

검출률 93.8% · 시연 목표 충족

새 독립 데이터 검증 필요

비율 선택 후, 같은 Test에서 확인

Test 지표	최선 단일: CatBoost	선택한 비율
불량 발견 / 전체 불량	30 / 32	30 / 32
정상 오판 / 전체 정상	21 / 224	19 / 224
Recall	93.8%	93.8%
Precision	58.8%	61.2%
F1	0.723	0.741
정상 오판률	9.4%	8.5%

설정한 시연 목표 충족 · 새 독립 데이터로 검증 필요

비율 선택에는 Test를 쓰지 않았습니다. 기존 프로젝트에서 이미 확인한 Test의 추가 탐색 결과이며 양산 승인 결과가 아닙니다.

⑥ 새 정답 데이터로 기존 모델을 점검합니다



재학습 필요
기존 CatBoost의 모델과 판정값을 바꾸지 않고 점검했습니다.

같은 제품	이전 Test 검출률	새 데이터 검출률	새 데이터 정상 오판률	제안
A	4/4개	37/112개	20.5%	재학습 비교 제안
B	3/4개	45/130개	18.1%	재학습 비교 제안
C	10/14개	35/121개	20.7%	재학습 비교 제안
D	10/10개	33/109개	22.3%	재학습 비교 제안

점검 기준: 불량 표본 20개 이상에서 검출 목표 미달·정상 오판 목표 초과·이전보다 Recall 10%p 넘게 하락 시 재학습 비교를 제안합니다. 표본이 부족하면 판단을 보류합니다.

같은 제품·같은 모델·같은 판정 경계값으로 새 배치의 학습 구간을 점검. 10%p 하락·불량 20개는 교육용 점검 규칙이며 회사 기준·통계적 확증이 아님. 과거 제품별 표본이 작으면 하락 폭도 탐색적 해석. 새

새 배치의 정답으로 기존 모델 그대로 점검

검출 목표 미달
재학습 비교 제안

표본이 부족하면
판단 보류

판단 근거를 확인한 뒤 학습 계획을 승인합니다. 입력 변화만으로 즉시 교체하지 않습니다.

⑦ 승인 후 재학습하고, 같은 Test에서 비교합니다

재학습 전후, 새 배치의 같은 Test에서 확인했습니다

CatBoost 알고리즘은 유지하고 새 Train으로 다시 학습했습니다. 불량 167개·정상 601개를 같은 정답으로 비교합니다.

> **시연 목표 충족 · 재학습 후보 저장**
> 불량 발견 43개 → 153개 · 놓친 불량 124개 → 14개 · 정상 오판 96개 → 79개

같은 Test에서 측정	기존 모델 그대로	같은 알고리즘 재학습
실제 불량을 발견	43 / 167개	153 / 167개
놓친 불량	124개	14개
정상을 불량으로 오판	96 / 601개	79 / 601개
불량 검출률 (Recall)	25.7%	91.6%
정상 오판률	16.0%	13.1%
Precision · 잡은 것 중 실제 불량	30.9%	65.9%

불량 발견
43 → 153 / 167개

Recall
25.7% → 91.6%

정상 오판
96 → 79개

같은 CatBoost·새 배치의 같은 Test에서 비교했습니다. 후보를 저장하고 운영 모델은 유지합니다.

역할을 나누고, 실행과 답변을 검증했습니다

LangGraph 역할 연결 · 로컬 Qwen 설명 · MCP 조회·계획 도구

RAG: 내부 근거·공식 문서 → BGE-M3 임베딩 → FAISS 검색 → Qwen에 근거 전달

데이터 점검
행·결측·라벨

→

근거 검색
BGE-M3 · FAISS

→

실험 계획
모델·전처리·비교 범위

→

엔지니어 승인
확인 후 실행 허용

실험·재학습 엔진 학습·지표·후보 버전 기록 → 결과 검토 역할이 근거 정리

LangSmith: 실제 실행 추적 · API 재조회 확인

설명 검사(LLM-as-a-Judge): 6/8개 올바른 판단 · 코드 테스트 52개 통과

선택 근거와 검증 실패를 함께 남깁니다

- 성과: 모델 실험과 기존 모델 점검·승인 후 재학습을 연결
- 교훈: 후보 선택 때 좋아도, 마지막 시험에서는 실패할 수 있습니다.
- 한계: 합성 데이터·작은 불량 표본·반복 비교 → 현장 효과 미측정
- 개선: 독립 기간 검증 · 상시 데이터 감시 · 운영 버전 전환·복구

비율을 섞기 전, 개별 모델 비교

전체 제품 Train의 24조건에서 알고리즘별 최선 불균형 설정을 표시합니다.

앙상블은 같은 학습 범위의 CatBoost·HistGradientBoosting·LightGBM으로 비교했습니다.

모델 · 전체 제품 학습	불균형 설정	검출률	정상 오판률	F1
CatBoost	none	100.0%	9.3%	80.8%
HistGradientBoosting	none	100.0%	10.3%	79.2%
LightGBM	none	100.0%	10.7%	78.5%
XGBoost	none	100.0%	11.2%	77.8%
Random Forest	none	100.0%	13.1%	75.0%
AdaBoost	none	97.6%	6.1%	85.4%
SVM (RBF)	weighted	97.6%	10.7%	77.4%
Gradient Boosting	none	97.6%	11.7%	75.9%
MLP / ANN	none	97.6%	14.5%	71.9%
Decision Tree	none	92.9%	8.4%	78.8%
KNN	none	92.9%	11.2%	74.3%
Logistic Regression	weighted	90.5%	18.7%	63.3%

공식 문서에서 비교 후보를 추가할 수 있습니다

공식 문서 검색 → 근거를 Qwen에 전달

BGE-M3 임베딩 + FAISS 벡터 저장·검색

실제 학습 연결: ExtraTrees·GaussianNB 두 후보 · 계획 승인 후 비교



선택이 최적이라는 말은 어디까지인가요?

실험1: 알고리즘·설정 고정 → 제품 그룹15개 구성 비교

실험2: 학습 제품ABCD 고정 → 세 모델의 혼합 비율232개 비교

두 실험은 각각 조건을 통제했습니다. 그룹과 비율의 공동 전역 최적화가 아닙니다.

선택은 Validation에서, 선택 후 확인은 Test에서 수행했습니다.

기존 Test 재사용·작은 제품별 불량 표본 → 새 독립 기간 검증 필요

LLM-as-a-Judge: 설명이 맞는지 LLM이 검사합니다

검사용 기준: 이전 실험에서 불량27/32개 발견 · 목표90%에는 미달

실제 결과와 설명 문장을 주고 “맞는 설명인가?”를 물었습니다.

직접 만든 예제 8개 중 6개는 맞게 검사했고, 2개는 틀렸습니다.

검사할 설명	맞는 판단	LLM의 실제 답
“불량27개를 찾았고 목표에는 미달했다”	맞는 설명	맞다 · 올바른 검사
“실제 공장 수율 증가가 입증됐다”	근거 없는 설명	틀리다 · 올바른 검사
“불량30개를 발견했다”	실제는27개 → 틀림	맞다 · 검사가 틀림

과제 기술 요소와 실제 구현 위치

기술 요소	구현과 확인
Multi-Agent · LangGraph	점검·검색·계획 역할 연결 / 로컬 Qwen 설명
MCP	조회·계획 4개 도구와 지식 Resource
RAG	BGE-M3 임베딩 / FAISS 검색 / Qwen에 근거 전달
모듈화 · DI · 단위/API 테스트	학습·점검·저장 분리 / 의존성 주입 / 52개 통과
LangSmith	APAC 실제 계획 생성·하위 실행 API 재조회
LLM-as-a-Judge	개발 예제 8개 중 6개 판정 일치 / 오판 보존
모델 성능 관리	새 정답 배치 점검 / 승인 재학습 / 전후 비교·후보 저장