반도체 검사 모델 실험 도우미

데이터를 점검하고, 승인받아 모델을 비교하고, 선택 근거를 보여 줍니다.

SKALA 광주 2반 · G045 김용찬 · 2026.10.22

01
데이터 점검

02
계획 승인

03
실제 비교

04
선택 근거

데이터가 다르면 비교할 모델도 달라집니다

사용자: 새 검사 데이터로 정상·불량 분류 모델을 만드는 엔지니어

전처리 → 모델 비교 → 근거 정리 → 추가 실험을 매번 반복합니다.

데이터	교육자료의 모델 예시	이번 구현
숫자 센서	Tree · KNN · SVM · ANN	여러 분류 모델 실제 학습
검사 이미지	ResNet · VGGNet · Autoencoder	자체 축소 구조 3종 실제 학습
로그 / 시계열	BERT·GPT / LSTM·ARIMA	향후 확장

Agent는 계획과 근거, 엔지니어는 승인을 맡습니다

LangGraph로 점검·검색·계획 역할을 연결하고, 승인된 계획만 실행합니다.

데이터 점검
행·결측·라벨·분할

→

근거 검색
교육 근거 / 공식 문서

→

실험 계획
모델·전처리·예산

→

엔지니어 승인
계획·데이터 hash 확인

승인 후 학습·평가
Train 학습 → Validation 선택 → 고정 Test 확인

기본 모델과 후보 결과 비교
불량 발견·정상 오판 → 기준 충족 여부 확인

MCP는 조회·계획 도구를 제공하고, LangSmith는 실행 경로를 추적합니다.

① 데이터를 선택하고 비교 계획을 요청합니다

제품 A–D · 1,280건 · 불량 201건

A–D는 가상 제품명입니다.

첫 사용: 예제 데이터 준비 → 센서 선택 → 비교 계획 제안받기



② 전처리·모델·분할을 확인한 뒤 승인합니다

Train 768 / Validation 256 / Test 256

같은 생산 묶음(lot)은 구간 사이에 섞지 않습니다.

여러 후보·불균형 설정을 비교한 뒤 상위 후보의 제품 조합 확장

최대 52조건 · 완전탐색은 아닙니다.



③ Validation으로 후보를 고르고 이유를 남깁니다

선택 규칙: Recall ≥ 90% · 정상 오판률 ≤ 15% 목표 충족 우선

충족 후보 중 Recall 우선, 동률이면 정상 오판률이 낮은 후보

상위 2모델의 제품 조합 비교 → CatBoost · A+B+C 선택

전체 제품 학습 · Validation	Recall	정상 오판률	F1
CatBoost	100.0%	9.3%	80.8%
HistGradientBoosting	100.0%	10.3%	79.2%
AdaBoost	97.6%	6.1%	85.4%
Logistic Regression	90.5%	18.7%	63.3%

같은 Test 256건 · 불량 32건 / 정상 224건

④ 더 찾았지만, 목표에는 못 미쳤습니다

기본: Logistic Regression / 선택 후보: CatBoost · A+B+C

후보 Recall 84.4% < 목표 90% → 추가 실험 필요

같은 Test에서 비교	기본 모델	선택 후보
불량 발견	20 / 32개	27 / 32개
놓친 불량	12개	5개
정상 오판	1 / 224개	14 / 224개
Recall	62.5%	84.4%

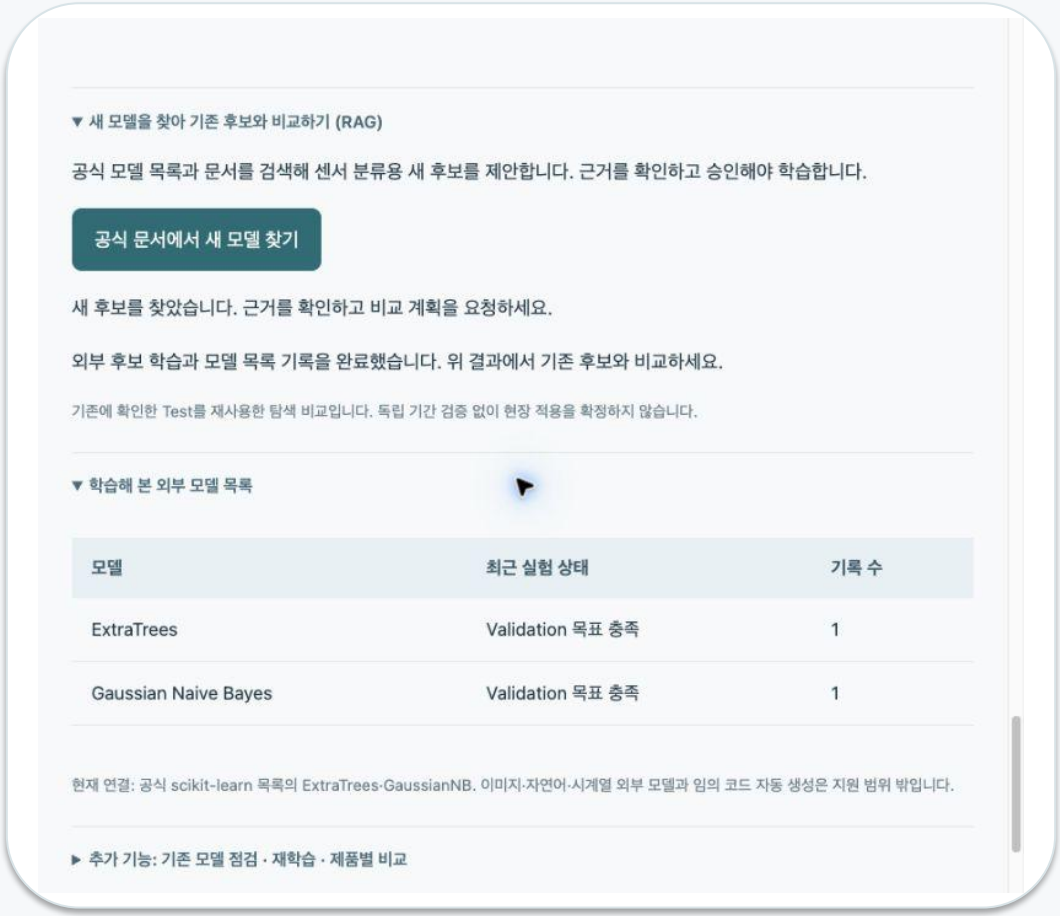
공식 문서에서 비교할 후보를 추가할 수 있습니다

공식 모델 목록·문서 조회 → 근거 검색 → 새 비교 계획 → 승인·학습

ExtraTrees · GaussianNB를 기존 후보와 비교하고 목록을 갱신

기록된 추가 실험에서는 CatBoost 유지

현재 실행 가능한 범위: 검토된 두 모델 adapter



실험 경로와 실패 상태를 기록합니다

LangGraph 역할 분리 · MCP 4도구와 지식 Resource · 의존성 주입

로컬 Qwen2.5 · RAG 근거 검색 · 공식 문서에서 비교 후보 추가

LangSmith APAC: 실제 계획 생성과 하위 실행 API 재조회 성공

LLM 평가 6/8 예제 일치 · 테스트 33개 통과

experiment.propose → LangGraph → 점검 · 검색 · 계획

API 재조회 성공 · child run 10개 · 78b9a699-ccfe-4533-a4f8-f0cbc021894b

LLM은 근거와 설명을 보조하고, 모델 학습·지표 계산·후보 순위는 실험 엔진이 담당합니다.

선택한 모델과 선택 이유를 함께 보여 줍니다

구현: 데이터 점검 → 계획 승인 → 모델 비교 → 선택 근거·지표 확인

교훈: Recall을 높이면 정상 오판도 늘 수 있고, 선택 규칙이 결론을 바꿉니다.

한계: 합성 데이터·작은 불량 표본·반복 Validation·Test 재사용 탐색

다음: 현장 기준 합의 → 독립 기간 검증 → 엔지니어 작업시간 측정

부록 · 알고리즘마다 최선 불균형 설정 1개 표시

모델별 Validation 비교

같은 전체 제품 Train에서 비교했습니다. 이 표는 제품 조합 확장 전 단계입니다.

후보별 판정값은 Validation에서 조정했습니다. Test 전체 모델 순위가 아닙니다.

모델 · 전체 제품 학습	불균형 설정	Recall	정상 오판률	F1
CatBoost	none	100.0%	9.3%	80.8%
HistGradientBoosting	none	100.0%	10.3%	79.2%
LightGBM	none	100.0%	10.7%	78.5%
XGBoost	none	100.0%	11.2%	77.8%
Random Forest	none	100.0%	13.1%	75.0%
AdaBoost	none	97.6%	6.1%	85.4%
SVM (RBF)	weighted	97.6%	10.7%	77.4%
Gradient Boosting	none	97.6%	11.7%	75.9%
MLP / ANN	none	97.6%	14.5%	71.9%
Decision Tree	none	92.9%	8.4%	78.8%
KNN	none	92.9%	11.2%	74.3%
Logistic Regression	weighted	90.5%	18.7%	63.3%

데이터를 바꾸면 후보와 결론도 달라집니다

합성 센서·이미지는 실제 공장 데이터가 아닙니다. SECOM은 실제 공개 센서 자료입니다.
각 데이터의 Test는 서로 다릅니다. 모델의 종합 순위로 해석하지 않습니다.

데이터	기본 / 선택·참고 후보	불량 발견	정상 오판	판단
합성 센서	Logistic / CatBoost	20 → 27 / 32	1 → 14 / 224	추가 실험 필요
UCI SECOM	Logistic / XGBoost	0 → 5 / 23	17 → 87 / 357	목표 충족 후보 없음
합성 이미지	축소 ResNet / Autoencoder	15 → 14 / 15	32 → 0 / 105	불량 표본 보강

Recall만 높으면 좋은 모델인가요?

- Recall: 실제 불량 중 찾아낸 비율 / 정상 오판률: 정상을 불량으로 잘못 본 비율
- 전부 불량이라고 판단하면 Recall은 높지만 정상 오판도 커집니다.
- 먼저 담당자와 불량 미검출·정상 오판의 허용 범위를 정합니다.
- 이번 90%·15%는 교육용 목표이며 회사의 공통 양산 기준이 아닙니다.
- Precision·F1도 함께 보고, 작은 불량 표본의 불확실성을 확인합니다.

6:2:2는 사전 고정, 혼합 비율은 별도 실험입니다

- Train: 모델 학습 / Validation: 모델·제품 조합·판정값 선택 / Test: 선택 결과 확인
- 합성 센서 768 / 256 / 256 · 후보 A+B+C는 Train 중 544건 학습
- SECOM은 날짜 블록 60/20/20 → 실제 행 수 820 / 367 / 380
- RF·부스팅은 사용 · 서로 다른 모델의 혼합 가중치 탐색은 미구현
- 확장 시: 사전에 정한 가중치를 Validation으로 고르고 새 Test로 확인

구현한 기술과 남은 범위를 구분합니다

과제의 기술 목록 전체를 구현했다고 주장하지 않습니다.

요소	구현·증빙	현재 한계
Multi-Agent / LangGraph	점검·검색·계획·결과 검토 역할	고정 그래프 · 자율 Supervisor 미구현
RAG	TF-IDF / 선택적 Qwen 임베딩·cosine	별도 Vector DB 미도입 · 14개 소규모 근거
외부 모델 탐색	공식 문서 검색·ExtraTrees/GaussianNB	검토된 두 adapter만 지원
MCP	stdio 4도구 + 지식 Resource	승인·학습 실행은 API에서만
코드 품질	모듈화·DI·단위/API 테스트	배포·동시 다중 사용자 미검증
LangSmith	실제 root/child trace API 재조회	LLM 응답 성공과 별도
LLM-as-a-Judge	로컬 Qwen으로 설명과 실제 결과 비교	자체 예제 6/8개에서 사전 라벨과 일치 · 독립 평가 아님

출처와 재현 자료

- 모델 참고: 스칼라 9주차 수업 + 15주차 반도체 발표자료
- SECOM: McCann & Johnston (2008), UCI · DOI 10.24432/C54305 · CC BY 4.0
- 측정 원본: docs/evaluation/ · 고정 seed 45 · 기존 Mac 결과와 Windows 검증 구분
- 소스·최종 보고서: github.com/dragonchan95/Semiconductor-AI-Agent
- 기존 Google Slides 주소는 README에 보존 · 온라인 갱신 여부는 별도 확인